NutriPet AI: Arquitetura Técnica, Stack Tecnológica e Roteiro de Implementação

Documento de Especificação de Engenharia e Arquitetura de Software

---

1. Visão Geral da Arquitetura de Sistema

A arquitetura do **NutriPet AI** adota um padrão modular, desacoplado e escalável, fundamentado na combinação de microserviços e serviços geridos em nuvem. A abordagem garante baixos custos operacionais na fase inicial (Bootstrapping / MVP) e fornece a elasticidade necessária para suportar a expansão da base de clínicas, médicos veterinários e tutores.

Componentes Chave da Arquitetura

- **Frontend / Client Apps:** Interface web e móvel responsiva unificada, provendo experiências distintas para Tutores e Médicos Veterinários. O controle de navegação e acesso a recursos é gerenciado por Controle de Acesso Baseado em Papéis (RBAC - *Role-Based Access Control*).
- **Backend API Gateway & Serviços:** Camada API RESTful modular encarregada da lógica de negócios central: autenticação, gestão de fichas clínicas longitudinais, versionamento de planos alimentares, agendamentos e métricas do paciente.
- **Pipeline Assíncrono de IA & OCR:** Barramento de eventos e processamento desacoplado em filas para ingestão documental de exames laboratoriais, extração estruturada de parâmetros bioquímicos e geração automatizada de rascunhos de relatórios.
- **Camada de Dados & Armazenamento:** Banco de dados relacional transacional com suporte a auditoria rigorosa, combinado a um armazenamento de objetos em nuvem configurado com criptografia em repouso e controle de acesso via URLs temporárias pré-assinadas.

[Client Apps (PWA / Web)]



---

2. Stack Tecnológica Recomendada

A seleção de tecnologias prioriza a produtividade do desenvolvimento, segurança tipo-estática (*type safety*), suporte robusto a ecossistemas de Inteligência Artificial e facilidade de manutenção de longo prazo.

A. Camada de Frontend

- **Framework: Next.js (React)** com **TypeScript** e **Tailwind CSS**. A escolha do Next.js permite *Server-Side Rendering* (SSR) para páginas públicas e *Client-Side Rendering* (CSR) para os painéis autenticados, oferecendo excelente desempenho e SEO.
- **Mobile Experience: Progressive Web App (PWA)** na fase inicial, garantindo instalação sem atrito em dispositivos iOS e Android. Evolução planejada para **React Native** caso seja exigida integração nativa profunda com sensores de hardware.

- **Componentes & Design System: Shadcn/ui** e **Radix UI**, garantindo componentes acessíveis, customizáveis e de alta fidelidade visual para dashboards analíticos e formulários médicos de alta complexidade.

B. Camada de Backend & Autenticação

- **Linguagem / Framework: Node.js com NestJS** ou **Python com FastAPI**.
    - *NestJS (TypeScript):* Estrutura enterprise opinativa com excelente suporte a arquitetura limpa e ecossistema consistente frontend-backend.
    - *FastAPI (Python):* Alternativa nativa para orquestração de bibliotecas de manipulação de dados e IA.
- **Autenticação & Identidade: Supabase Auth** ou **Auth0**, com suporte nativo a autenticação multifator (MFA), gerenciamento de sessões seguras e atribuição flexível de funções (Tutor, Veterinário, Administrador da Clínica).

C. Persistência de Dados & Armazenamento

- **Banco de Dados Relacional: PostgreSQL** (hospedado em **Supabase**, **Neon** ou **AWS RDS**). Modelo relacional estrito para garantir integridade referencial sobre dados de pacientes, tutores, históricos de consulta e logs de auditoria.
- **Object Storage: AWS S3** ou **Cloudflare R2**. Os arquivos de exames são mantidos em buckets totalmente privados, sendo acessíveis exclusivamente via *Presigned URLs* com tempo de expiração curto (ex.: 15 minutos).

D. Pipeline de Inteligência Artificial e OCR

- **Extração de Texto (OCR): AWS Textract** ou **Google Cloud Document AI** para conversão primária de arquivos PDF e imagens em texto legível.
- **Modelos de Linguagem (LLM Multimodal): Gemini 1.5 Pro / Flash** ou **Claude 3.5 Sonnet**, utilizando chamadas de função (*Function Calling*) com validação estrita via **JSON Schema**.
- **Processamento Assíncrono: Redis** em conjunto com **BullMQ** (Node.js) ou **Celery** (Python) para gerenciamento de tarefas em segundo plano, retentativas e isolamento de falhas.

---

3. Fluxo de Engenharia: Pipeline de Exames (OCR + IA)

O processamento de exames laboratoriais é um fluxo crítico do sistema, desenhado para transformar documentos não estruturados em dados clínicos acionáveis com validação humana obrigatória (*Human-in-the-Loop*).

Etapa	Operação	Descrição Técnica
1. Upload Seguro	Ingestão	O cliente envia o laudo em PDF ou imagem. O backend valida o MIME type, calcula o hash SHA-256 para integridade e armazena o arquivo no Object Storage privado.
2. Enfileiramento	Desacoplamento	A API publica um evento na fila `exam-processing`. A resposta é devolvida imediatamente ao cliente com o status `processing`.
3. OCR & Extração	Processamento	O worker obtém o documento, executa o OCR para extração de layout/texto e invoca o LLM fornecendo o schema JSON estrito de saída.
4. Marcação de Dúvidas	Tratamento	Parâmetros que apresentem ruído visual, unidades não padronizadas ou ausência de intervalo de referência recebem a flag `is_uncertain: true`.
5. Revisão Humana	Interface HIL	O veterinário visualiza o documento original ao lado do formulário pré-preenchido.

Etapa	Operação	Descrição Técnica
		Campos incertos são destacados visualmente para validação ou edição.
6. Persistência Final	Imutabilidade	Após a confirmação do profissional, os dados estruturados são gravados nas tabelas definitivas do paciente com registro de auditoria da alteração.

Schema de Saída do Pipeline de Extração (JSON Schema)


```
{
  "exam_metadata": {
    "laboratory_name": "LabVet Diagnósticos",
    "exam_date": "2024-10-15",
    "patient_name": "Thor"
  },
  "results": [
    {
      "parameter": "Eritrócitos",
      "value": 6.8,
      "unit": "terras/L",
      "reference_range": "5.5 - 8.5",
```

```
    "is_uncertain": false,
    "confidence_score": 0.98
  },
  {
    "parameter": "Proteína Total",
    "value": 72.0,
    "unit": "g/L",
    "reference_range": "54.0 - 71.0",
    "is_uncertain": true,
    "uncertainty_reason": "Unidade fora do padrão habitual (g/dL)",
    "confidence_score": 0.65
  }
 ]
}
```


---

4. Segurança, Governança e Conformidade (LGPD)

O NutriPet AI lida com dados pessoais de tutores e dados sensíveis de prática profissional clínica. O sistema foi projetado em estrita observância à Lei Geral de Proteção de Dados (LGPD).

- **Criptografia Ponta a Ponta:** Todo o tráfego de rede é forçado via **TLS 1.3**. Os dados em repouso no PostgreSQL e no Object Storage utilizam criptografia **AES-256**.

- **Isolamento de Dados & Controle de Acesso:** Implementação do Princípio do Menor Privilégio (*Least Privilege*). Tutores possuem acesso restrito aos perfis dos animais a eles vinculados. URLs para download de laudos são efermeras.
- **Trilha de Auditoria Inviolável (Audit Log):** Qualquer operação de leitura, modificação ou exclusão (*CRUD*) realizada em registros clínicos gera uma entrada imutável no banco contendo: `user_id`, `action`, `resource_type`, `resource_id`, `ip_address` e `timestamp_utc`.
- **Governança de Dados de IA:** Cláusulas contratuais e configurações de API garantem que nenhum dado de paciente ou documento submetido seja utilizado para o treinamento de modelos públicos ou genéricos das provedoras de IA.

---

5. Roteiro Prático de Execução (Fases de Desenvolvimento)

O cronograma de desenvolvimento está estruturado em 4 fases sequenciais, totalizando 15 a 17 semanas até o lançamento da versão comercial completa.

Cronograma de Implementação

Fase	Foco Principal	Entregáveis Chave	Duração
Fase 1	MVP de Fundação	• Autenticação RBAC (Tutor vs. Veterinário)• Cadastro de pacientes, raças e tutores• Prontuário longitudinal e registro de peso / Escore de Condição Corporal (ECC)	4 a 6 semanas
Fase 2	Planos e Documentos	• Cadastro e versionamento de planos alimentares• Upload seguro de laudos e exames (S3/R2)• Visualização controlada de documentos por perfil	4 semanas

Fase	Foco Principal	Entregáveis Chave	Duração
Fase 3	Pipeline de IA e OCR	• Infraestrutura de filas assíncronas (Redis + BullMQ)• Extração multimodal com JSON Schema estrito• Interface side-by-side para revisão do veterinário	4 semanas
Fase 4	Engajamento & Relatórios	• Painel de acompanhamento de adesão para tutores• Sistema de notificações (lembretes de pesagem e consultas)• Geração automatizada de rascunhos de relatórios evolutivos	3 semanas

---

6. Próximos Passos Recomendados

1. **Configuração do Ambiente Dev:** Inicialização do repositório monorepo ou multi-repo com definições de ESLint, Prettier e pipelines de CI/CD via GitHub Actions.
2. **Modelagem de Banco de Dados:** Execução das migrações iniciais no PostgreSQL para as tabelas `users`, `patients`, `consultations` e `audit_logs`.
3. **Prototipagem da Interface de Validação:** Construção do componente visual de revisão lado a lado (*PDF Viewer* + *Formulário Dinâmico*) no Next.js para validação antecipada da experiência do usuário médico.