NutriPet AI

Arquitetura técnica e plano de implementação

Documento técnico de planejamento • 11 de outubro de 2026

Recomendação inicial sujeita a validação de requisitos, equipe, orçamento e riscos.

1. Objetivo e princípios

Este documento recomenda uma estrutura técnica inicial para construir o NutriPet AI como uma aplicação web responsiva para profissionais e tutores de cães e gatos. A proposta parte do documento conceitual do produto: ficha longitudinal, atendimentos, planos alimentares versionados, exames, evolução, relatórios, permissões por perfil e IA como apoio revisável.

A arquitetura abaixo é uma recomendação de engenharia, não uma decisão já validada por implementação. O escopo e as tecnologias devem ser confirmados após um protótipo e conversas com profissionais. O documento não garante conformidade legal, segurança absoluta ou adequação clínica.

- Começar por um monólito modular bem organizado, não por microserviços. Isso reduz complexidade operacional e facilita mudanças enquanto o produto está sendo validado.
- Separar interface, regras de negócio, dados, arquivos e processamento de IA.
- Projetar permissões e auditoria desde o início, porque o sistema pode conter dados pessoais dos tutores e documentos associados ao cuidado animal.
- Preservar os documentos originais, registrar a origem dos dados extraídos e nunca apresentar saída de IA como parecer aprovado sem revisão.
- Priorizar um MVP que prove economia de tempo antes de implementar formulação nutricional avançada ou integrações complexas.

2. Arquitetura recomendada em uma visão

Estrutura inicial recomendada: aplicação web responsiva; API/backend único com módulos separados; banco relacional PostgreSQL; armazenamento privado de arquivos compatível com S3; fila de tarefas para OCR e IA; provedor de modelos acessado por uma camada de integração; monitoramento, logs e backups.

```
Navegador (profissional / tutor) → Frontend web → API/backend → PostgreSQL
■ armazenamento privado de arquivos
■ fila de tarefas → OCR/IA → resultado pendente de revisão
■ logs, métricas, auditoria e alertas
```

A fila de tarefas impede que a interface fique esperando durante a leitura de documentos. O backend controla autorização, validação e transições de estado. O modelo de IA não deve acessar diretamente o banco de dados de produção.

3. Stack tecnológica sugerida

3.1 Frontend

- Next.js com React e TypeScript: adequado para uma interface web responsiva, formulários, dashboards e rotas protegidas.
- Biblioteca de componentes acessível e consistente, escolhida após um protótipo visual; manter componentes simples e testáveis.
- Validação de formulários com schemas compartilhados quando fizer sentido, para reduzir divergências entre interface e API.

Alternativa: React com Vite se não houver necessidade de recursos do framework Next.js. A escolha deve priorizar simplicidade da equipe e velocidade de manutenção.

3.2 Backend

- Python com FastAPI: boa opção para APIs e integração com OCR, processamento documental e bibliotecas de IA.
- Organizar o backend em módulos: identidade e acesso; tutores e animais; atendimentos; medições; planos; documentos; extrações; revisões; relatórios; auditoria.
- Usar migrações versionadas para alterações de banco e contratos de API documentados.

Alternativa: TypeScript com NestJS caso a equipe seja mais experiente em JavaScript/TypeScript. Evitar manter duas linguagens no backend sem uma necessidade clara.

3.3 Banco de dados

- PostgreSQL como banco relacional principal, com chaves estrangeiras, restrições, índices e transações.
- Usar migrations e dados de teste separados. Nunca executar testes destrutivos contra o banco de produção.
- SQLite pode servir para protótipos locais simples, mas não é a recomendação padrão para o ambiente multiusuário de produção.

3.4 Arquivos e tarefas

- Armazenamento privado de objetos compatível com S3 para PDFs, imagens e relatórios, com acesso temporário e política de retenção.
- Fila de tarefas e worker separado para OCR, extração de dados, geração de rascunhos e notificações. A tecnologia concreta da fila deve ser escolhida conforme a hospedagem e o volume.

3.5 Autenticação

Usar um provedor de identidade confiável ou implementar autenticação com biblioteca consolidada, sessões seguras, recuperação de acesso, proteção contra abuso e MFA para perfis privilegiados. A decisão entre provedor gerenciado e autenticação própria depende de orçamento, requisitos de controle e capacidade operacional.

4. Componentes e responsabilidades

- Frontend: telas, formulários, estados de revisão, visualização do histórico e experiência de tutor/profissional. Não é fonte de verdade para permissões.
- API: autenticação, autorização por papel e vínculo, validação, regras de negócio, paginação, auditoria e integração entre módulos.
- Banco relacional: dados estruturados de tutores, animais, atendimentos, medições, planos, extrações, revisões e auditoria.
- Armazenamento de arquivos: documentos originais e saídas exportadas, sempre privados por padrão.
- Worker de documentos: antivírus/validação de tipo quando disponível, OCR, extração, normalização segura e criação de rascunhos.
- Camada de IA: encapsula fornecedores, modelos, prompts versionados, limites de entrada, registro de versão e tratamento de falhas.
- Auditoria e observabilidade: eventos relevantes, erros técnicos, duração de tarefas, taxa de falha e ações administrativas, sem registrar desnecessariamente dados sensíveis em logs.

5. Modelo de dados inicial

O modelo abaixo é uma base inicial a validar com profissionais. Não substitui modelagem detalhada nem avaliação de requisitos legais.

- User: identidade, estado da conta e referência ao provedor de autenticação.
- Organization/Clinic: clínica ou organização, configurações e plano comercial futuro.
- Membership/Role: vínculo de usuário com organização, papel e permissões.
- Tutor: identificação e contatos estritamente necessários, preferências e registros de consentimento quando aplicáveis.
- Animal: tutor, nome, espécie, raça, data de nascimento aproximada quando conhecida, sexo e estado do cadastro.
- Appointment/Encounter: animal, tipo, data, profissional, status, observações e próximo acompanhamento.
- Measurement: animal/atendimento, tipo, valor, unidade, data, método e observação.
- NutritionPlan e NutritionPlanVersion: plano, vigência, itens, quantidades, unidades, metas, autoria e aprovação.
- ExamDocument: animal, atendimento, arquivo original, hash, laboratório, datas e metadados.
- ExamObservation: parâmetro original/normalizado, resultado, unidade, referência, página/região de origem e confiança.
- AIAnalysis: tipo de tarefa, modelo/versão, versão do prompt, entradas referenciadas, saída, limitações e estado.
- ProfessionalReview: revisor, decisão, correções, justificativa, data e versão aprovada.

- AuditEvent: ator, ação, entidade, data/hora e contexto mínimo necessário.

Entidades com dados clínicos devem sempre estar associadas a uma organização e/ou a um vínculo de acesso autorizado. As regras de isolamento entre clínicas precisam ser testadas explicitamente.

6. Fluxo seguro de exames com OCR e IA

- 1. Usuário autorizado envia PDF ou imagem; a API valida tamanho, tipo e vínculo com animal/atendimento.
- 2. Arquivo original é armazenado de forma privada e recebe identificador e hash para rastreabilidade.
- 3. Uma tarefa é colocada na fila; a interface mostra “aguardando processamento”.
- 4. Worker executa OCR e extração estruturada; cada campo deve manter página/região de origem quando tecnicamente possível.
- 5. Valores ilegíveis, unidade ausente, referências incompatíveis ou baixa confiança ficam marcados como incertos. Não completar lacunas com valores inventados.
- 6. A IA prepara uma análise preliminar, separando fatos extraídos, observações automatizadas e limitações.
- 7. Profissional autorizado confirma, corrige, rejeita ou solicita nova extração.
- 8. Somente a versão aprovada pode ser publicada ao tutor ou incorporada a um relatório final.
- 9. Guardar versão, modelo, prompt, data, revisor e alterações relevantes para auditoria.

A IA não deve diagnosticar autonomamente nem recomendar mudanças terapêuticas com base apenas em um exame isolado. A qualidade precisa ser medida com um conjunto de documentos de teste autorizado e representativo antes do uso operacional.

7. Segurança, privacidade e LGPD

- Acesso mínimo necessário: aplicar autorização no backend em todas as rotas e operações, não apenas esconder botões na interface.
- Isolamento por organização: testar se um usuário de uma clínica não consegue consultar registros ou arquivos de outra, inclusive por IDs e URLs diretas.
- Arquivos privados: evitar links públicos permanentes; usar URLs temporárias e verificar autorização antes de gerá-las.
- Proteção de dados em trânsito e em repouso conforme os recursos da hospedagem e dos serviços escolhidos.
- Segredos e chaves de API fora do código-fonte; separar ambientes de desenvolvimento, teste e produção.
- Auditoria: registrar acessos e alterações relevantes, sem armazenar conteúdo sensível em excesso.
- Backups criptografados quando suportado, retenção definida e testes regulares de restauração.
- Definir finalidade, base legal, minimização, retenção, exportação, correção, exclusão e processo de atendimento a incidentes.
- Revisar contratos dos fornecedores de IA e hospedagem: uso dos dados, retenção, região de processamento, suboperadores e opções de não treinamento.

A aplicação da LGPD depende dos dados e das operações reais. Antes do lançamento, obter revisão jurídica e técnica. Este documento não representa certificação ou garantia de conformidade.

8. Estratégia de IA e controle de custos

- Criar uma interface interna única para provedores de IA, permitindo trocar fornecedor sem reescrever os módulos de negócio.
- Começar com tarefas delimitadas: extração de campos, resumo de evolução e rascunho de relatório.
- Usar OCR dedicado ou serviço documental quando apropriado; não presumir que um LLM sozinho seja a solução mais confiável para todos os PDFs.
- Guardar métricas por tarefa: custo estimado, latência, falhas, necessidade de correção e taxa de campos confirmados.

- Aplicar limites de tamanho, páginas, tentativas e tempo; permitir reprocessamento controlado e evitar duplicidade de cobranças.
- Usar dados fictícios ou desidentificados durante desenvolvimento e avaliação sempre que possível.

Não escolher agora um único fornecedor de IA com base apenas em preço de token. Comparar qualidade em documentos reais autorizados, custo por exame processado, latência, estabilidade, termos de privacidade e facilidade de monitoramento.

9. Hospedagem e operação

Para um MVP, escolher hospedagem gerenciada que reduza trabalho de manutenção, com ambientes separados e serviços de banco e arquivos confiáveis. Uma VPS pode reduzir alguns custos diretos, mas transfere para a equipe responsabilidades de atualização, segurança, monitoramento, backups e recuperação.

- Ambiente local: desenvolvimento e testes com dados sintéticos.
- Ambiente de staging: validação de releases e testes de aceitação, com acesso limitado.
- Produção: domínio e HTTPS, segredos separados, banco com backup, armazenamento privado, logs, alertas e procedimento de rollback.
- CI/CD: testes automatizados e verificação de migrações antes de publicar; aprovação manual para mudanças de maior risco.

A escolha entre VPS própria, plataforma gerenciada ou nuvem pública deve considerar volume esperado, localização dos dados, custo total, competência operacional, SLA, facilidade de restauração e contratos. Não é responsável indicar preço exato sem estimar volume de arquivos, exames por mês, usuários, chamadas de IA e requisitos de disponibilidade.

10. Testes e critérios de qualidade

- Testes unitários: regras de domínio, permissões, cálculos e validações.
- Testes de integração: banco, armazenamento, fila e provedores externos.
- Testes de autorização: acesso cruzado entre organizações, perfis, animais e documentos.
- Testes de interface: fluxos principais em celular e computador.
- Testes de documentos: PDFs digitais, escaneados, baixa qualidade, múltiplas páginas, unidades ausentes e formatos variados.
- Avaliação de IA: precisão por campo, taxa de erro grave, taxa de revisão/correção, latência e custo por documento.
- Testes de backup/restauração: demonstrar que banco e arquivos podem ser recuperados de forma consistente.
- Critério de liberação: nenhuma falha crítica de autorização conhecida; fluxo de revisão funcional; origem do dado visível; falhas e incertezas tratadas; restauração testada.

11. Monitoramento e resposta a falhas

- Monitorar disponibilidade, latência da API, erros por rota, tamanho da fila, tempo de processamento, falhas de OCR/IA e uso de armazenamento.
- Criar alertas para falhas repetidas, fila parada, backup não concluído e aumento anormal de consumo.
- Registrar incidentes, impacto, causa, correção e ações preventivas.
- Definir procedimento para desativar temporariamente uma integração de IA sem perder o acesso aos registros já salvos.
- Manter exportação dos dados e plano de recuperação; evitar dependência irrecuperável de um único fornecedor.

12. Roadmap de implementação

Fase 0 — Descoberta e protótipo

- Entrevistas com profissionais, mapeamento de fluxo atual, protótipo de ficha e relatório e definição de critérios de sucesso.
- Aceite: usuários-alvo conseguem completar os fluxos principais e identificam uma dor relevante que vale testar.

Fase 1 — Fundação técnica

- Autenticação, organizações, perfis, permissões, banco, armazenamento privado, auditoria e backups.
- Aceite: dados persistem e usuários só acessam o que está autorizado; restauração de teste funciona.

Fase 2 — Prontuário nutricional

- Cadastro de tutores/animais, atendimentos, medições, linha do tempo e planos versionados.
- Aceite: histórico cronológico consultável, alterações rastreáveis e versões anteriores preservadas.

Fase 3 — Relatórios e IA assistiva

- Resumo de evolução e rascunhos revisáveis; depois, processamento de exames em fila.
- Aceite: cada resultado automatizado mostra origem, incerteza, versão e estado de aprovação.

Fase 4 — Piloto e endurecimento

- Piloto limitado, monitoramento, avaliação de qualidade, correção de falhas, documentação e treinamento dos usuários.
- Aceite: metas de uso e economia de tempo são medidas; riscos críticos tratados; profissionais aceitam continuar usando.

Fase 5 — Comercialização

- Planos, cobrança, suporte, onboarding, termos e políticas, revisão de segurança/jurídica e plano de continuidade.
- Aceite: operação e suporte conseguem atender clientes de forma previsível e os critérios legais/técnicos aplicáveis foram avaliados.

13. Equipe mínima e responsabilidades

- Responsável pelo produto: entrevistas, priorização, decisões de escopo e validação comercial.
- Desenvolvedor full-stack: interface, API, banco, autenticação, testes e deploy.
- Profissional de nutrição/veterinária consultor: validação dos fluxos, terminologia, limites clínicos e avaliação de relatórios.
- Apoio pontual de segurança/privacidade: revisão de arquitetura, contratos, riscos e requisitos legais antes do piloto com dados reais.

Uma pessoa pode acumular funções técnicas no protótipo, mas revisão clínica e avaliação de segurança não devem ser presumidas apenas por ter sido o próprio desenvolvedor quem implementou o sistema.

14. Plano prático para os primeiros 30 dias

Semana 1 — Descoberta

- Entrevistar profissionais; documentar o fluxo de atendimento atual; identificar ferramentas usadas, tarefas demoradas e dados mínimos necessários.

Semana 2 — Protótipo e critérios

- Criar protótipo navegável da ficha, linha do tempo e relatório; definir métricas de tempo, qualidade e intenção de pagamento.

Semana 3 — Fundação de desenvolvimento

- Criar repositório, ambientes, migrations, autenticação inicial, organização/perfis e primeiros testes de autorização com dados fictícios.

Semana 4 — Fluxo vertical demonstrável

- Implementar cadastro de animal, registro de atendimento, medição e geração de relatório de evolução sem IA ou com IA apenas em ambiente de teste; demonstrar o fluxo completo e colher feedback.

Resultado esperado ao final de 30 dias: uma hipótese de produto validada ou refutada parcialmente, um protótipo testável, arquitetura inicial documentada e um fluxo vertical funcionando com dados fictícios. O prazo depende da disponibilidade e experiência da equipe; não é uma garantia de entrega.

15. Decisões ainda em aberto

- Público inicial: profissional autônomo, clínica pequena ou serviço especializado.
- Escopo de nutrição: apenas acompanhamento e documentação no MVP ou inclusão posterior de formulação de dietas.
- Frontend e backend finais conforme competência da equipe.
- Provedor de autenticação, hospedagem, banco gerenciado e armazenamento de arquivos.
- Fornecedor de OCR/IA e regras de retenção/uso de dados de cada serviço.
- Volume esperado: usuários, animais ativos, exames e páginas por mês.
- Modelo comercial, preço, limites de uso, suporte e onboarding.
- Requisitos jurídicos e regulatórios aplicáveis, contratos, consentimentos e responsabilidades.

Não é necessário resolver todas essas decisões antes de criar o protótipo. É necessário resolvê-las antes de colocar dados reais e usuários externos em produção.

16. Conclusão

A arquitetura recomendada para o NutriPet AI é uma aplicação web responsiva com monólito modular, API bem delimitada, PostgreSQL, armazenamento privado de documentos, processamento assíncrono de exames e uma camada de IA substituível e auditável.

A prioridade técnica é estabelecer uma base segura de identidade, permissões, prontuário e histórico versionado. A IA deve entrar como ferramenta de apoio, com origem dos dados, tratamento explícito de incertezas e aprovação profissional. Integrações, formulação avançada de dietas e automações mais complexas devem vir depois da validação do núcleo.

O próximo passo mais racional é combinar descoberta comercial com um protótipo pequeno. O objetivo não é construir toda a plataforma de uma vez, mas demonstrar que o fluxo escolhido resolve uma dor relevante, é confiável e pode sustentar um negócio.

Apêndice — Diagrama simplificado

```
TUTOR / PROFISSIONAL
↓
FRONTEND WEB RESPONSIVO
↓
API + AUTENTICAÇÃO + AUTORIZAÇÃO
■ ↓ ■
POSTGRESQL ARQUIVOS FILA DE TAREFAS
PRIVADOS ↓
OCR / CAMADA DE IA
↓
RASCUNHO + INCERTEZAS
↓
REVISÃO PROFISSIONAL
↓
PUBLICAÇÃO AUTORIZADA
```